

算力固定下的推理服务分时动态定价： 异质厂家竞争、用户负载迁移与 QoS 保护机制

匿名作者

2026 年 6 月 18 日

摘要

大模型推理服务的 GPU 算力在短期内基本固定，而请求负载具有显著的时段性峰谷差：高峰时段过载导致拥塞与服务质量（QoS）退化，低谷时段算力闲置。本文研究一个现实问题：在算力固定的条件下，厂家能否通过**分时动态定价**（高峰提价、低谷降价）诱导时间弹性负载从拥塞高峰迁移到空闲低谷，从而在不扩容的前提下保护服务质量。我们建立一个异质双厂家竞争市场：两家部署同款开源模型（如 GLM）、服务近似同质的厂家各自拥有固定算力，一个可在两家之间路由的中间商，以及两类用户——时间刚性用户（交互式、实时，迁移成本高）与时间弹性用户（批量、离线，对低谷低价敏感）；用户还可经厂家直连 API 或外部退出选项离开。我们用低维形状参数化将每个厂家的分时定价压缩为少数标量，并以**虚拟博弈（fictitious play）**求解厂家间的 Nash 竞争——这一选择解决了朴素最优响应在拥塞区间出现的极限环振荡问题，使均衡求解可复现（非拥塞区间跨随机种子相对标准差为 4×10^{-4} ）。

实验给出一个经过对抗性鲁棒性检验的核心结论：**分时动态定价在市场拥塞时是可靠的 QoS 保护工具，但对厂家利润的影响近似中性，而非牟利手段**。在拥塞区间，统一定价使最低 QoS 跌至 0.756、峰值利用率达 0.782；动态定价将峰值利用率削至 0.66–0.71、最低 QoS 恢复到 0.97–0.99——这一 QoS 改善在粗、细两种网格分辨率下方向一致，是稳健的。但系统利润的变化在粗网格下为 +9.3%、在细网格下为 -1.9%，符号随求解精度翻转（且细网格求解未收敛），表明真实利润效应接近于零。我们从机制上解释这一“利润打平”：在算力与需求总量固定时，分时定价主要**重新分配剩余**而非创造剩余——高峰提价的增益被驱离的需求抵消，低谷填谷的增量被薄利抵消，而 QoS 改善带来的剩余在竞争与退出选项的约束下流向用户而非厂家利润。这一发现与“动态定价是厂家趁拥塞牟利”的通常预期相反，具有监管与运营含义：分时定价的正当理由是保障 SLA 与服务质量，而非提升收入。本文结论受限于合成参数标定，具体数值仅支撑机制方向，不作生产预测。

关键词：推理服务；动态定价；削峰填谷；异质厂家竞争；负载迁移；QoS 保护；虚拟博弈；剩余重分配

1 引言

1.1 研究背景与问题

大模型推理服务已经从离线批处理转向持续运行的在线服务。交互式聊天、代码生成、自动代理、批量评测和定时工作流在一天内呈现不同的到达规律，使 GPU 推理集群面临显著的峰谷差 [1, 2, 3, 4, 5]。当利用率接近容量边界时，首 token 延迟、排队时间和有效完成率快速恶化，服务质量（QoS）退化直接影响可结算服务量和用户满意度。

与可以快速调度发电或长期扩容的系统不同，推理服务的 GPU 算力在短期内**基本固定**——采购和部署有显著的前置时间和沉没成本，且低谷闲置的算力照样产生持有成本。这造成一个核心张力：高峰时段算力不足导致拥塞与 QoS 退化，低谷时段算力闲置造成浪费。一个自然的问题是：能否不依赖扩容，而是用**价格信号**把负载在时间上重新分配？

本文研究这一问题的一個具体形式：在算力固定的条件下，厂家通过**分时动态定价**（高峰提价、低谷降价），能否诱导对时间不敏感的负载从拥塞高峰迁移到空闲低谷，从而保护高峰期的服务质量。这一思路与电力市场的实时定价和需求响应同源 [6, 7, 8, 9, 10]，但推理服务的可计算约束不同：服务质量由 GPU 局部利用率、延迟和完成率决定，而非发电约束与网络潮流。

1.2 为什么需要竞争与异质性

现实推理服务市场并非单一厂家垄断。多个厂家可以部署同一款开源模型（例如 GLM 系列），向用户提供**近似同质**的服务，竞争主要落在价格与算力充裕度（QoS）上，而非模型能力差异。这一观察给竞争提供了真实的微观基础，也使本文与“单平台垄断定价”的简化区分开来。

此外，厂家的算力规模通常**异质**：老牌厂家算力充裕，新入场厂家算力紧张。算力异质会改变动态定价的策略空间——算力紧张的厂家更容易被路由来的流量打到拥塞。本文因此设定两家算力不同但服务同质的厂家，并保留一个可在两家之间路由的中间商（如 OpenRouter 类 API 聚合商），以及可绕过中间商直连厂家 API 或退出市场的用户。

1.3 贡献

1. **算力固定下的削峰填谷动态定价模型**。建立异质双厂家竞争、中间商路由、两类用户（时间刚性/弹性）加外部退出选项的市场模型，将厂家的固定算力闲置成本、QoS 拥塞退化和用户负载迁移纳入同一可计算框架。
2. **可复现的均衡求解**。用低维形状参数化加虚拟博弈（fictitious play）求解厂家间 Nash 竞争。我们识别并解决了朴素最优响应在拥塞区间的极限环振荡问题——这是同类多层定价博弈反复出现的收敛障碍；本文的求解在非拥塞区间达到跨种子相对标准差 4×10^{-4} ，在拥塞区间以 regret 判据单调收敛。
3. **经鲁棒性检验的 QoS 保护机制发现**。经粗、细网格的对抗性鲁棒性检验，给出一个诚实结论：分时动态定价在拥塞时**可靠保护 QoS（削峰、恢复完成率）但对厂家利润近似中性**。我们从剩余重分配的角度解释这一“利润打平”，并指出其与“动态定价牟利”预期相反的监管与运营含义。

2 模型

2.1 市场结构与时序

一天划分为 T 个时段 $\mathcal{T} = \{1, \dots, T\}$ ，每时段时长 h 。市场含：

- **两个异质厂家** $\mathcal{M} = \{A, B\}$ ，固定算力 $G_A > G_B$ ，部署同款开源模型（服务同质）。厂家 m 选择分时批发价 $w_{m,t}$ （卖给中间商）和分时直连零售价 $p_{m,t}^D$ （卖给用户）。

- 一个**中间商**，观察批发价后选择对用户的分时零售价 p_t 和把每时段流量分配给两厂家的路由权重 $r_{m,t}$ ($\sum_m r_{m,t} = 1$)。
- **两类用户**，按 logit 随机效用在”中间商通道、厂家 A 直连、厂家 B 直连、退出”之间选择。

时序为：厂家同时出价（Nash 竞争）→ 中间商最优响应 → 用户选择与 QoS 拥塞固定点。

2.2 两类用户与外部退出选项

设用户类型 $\theta \in \{R, E\}$ ， R 为时间刚性、 E 为时间弹性。类型 θ 对通道 k （中间商/厂家 A/厂家 B）在时段 t 的确定性效用为

$$z_{k,t}^\theta = \log b_k + \log a_t - \alpha_\theta (\text{price}_{k,t} - p_0) - c_s^\theta (1 - \pi_t^\theta) - \gamma(1 - q_{k,t}), \quad (1)$$

其中 b_k 为通道品牌/便利性， a_t 为时段偏好， π_t^θ 为类型 θ 的原生时段分布， $q_{k,t}$ 为通道 QoS。类型差异完全由参数承载：刚性用户价格敏感度 α_R 低、迁移成本 c_s^R 高、原生时段集中于高峰；弹性用户 α_E 高、 c_s^E 低、原生时段分散。

引入确定效用为 u_0 的 **no-purchase 外部退出选项** 进入 logit 归一化。类型 θ 选择通道 k 时段 t 的份额与退出概率为

$$s_{k,t}^\theta = \frac{\exp(z_{k,t}^\theta)}{\exp(u_0) + \sum_{k',t'} \exp(z_{k',t'}^\theta)}, \quad s_0^\theta = \frac{\exp(u_0)}{\exp(u_0) + \sum_{k',t'} \exp(z_{k',t'}^\theta)}. \quad (2)$$

内部份额之和 < 1 ，残余质量 s_0^θ 为真实退出概率，不被重新分配回内部选项。这保证了价格抬高时需求真正流失，而非被归一化掩盖。

2.3 需求、负载与 QoS

类型 θ 对通道 k 的需求由弹性项和刚性/重放项构成，二者均**按渠道自身份额**分配（使每时段刚性总量与渠道数无关）：

$$D_{k,t}^\theta = \bar{F}_\theta m(\mathbf{p}) s_{k,t}^\theta + \bar{R}_t^\theta \sigma[\beta(v_r - \text{price}_{k,t})] s_{k,t}^\theta. \quad (3)$$

总需求为两类人口加权之和，权重 (π_R, π_E) 。厂家 m 在时段 t 的总负载为直连需求加中间商按路由分来的需求：

$$L_{m,t} = D_{m,t}^D + r_{m,t} D_t^I, \quad u_{m,t} = L_{m,t}/G_m, \quad q_{m,t} = q(u_{m,t}). \quad (4)$$

QoS 退化函数 $q(u)$ 在利用率超过阈值 $\bar{u}$ 后下降。算力异质 $G_B < G_A$ 使同等负载下小厂 B 更易越过阈值而拥塞。本文主用平滑 sigmoid 退化形态（处处可微，利于均衡求解），并对阈值型、线性、根号形态做鲁棒性检验。

2.4 利润：含固定算力闲置成本

厂家 m 的利润为批发收入加直连收入，减去**按固定算力计的闲置成本**与 QoS 退化成本：

$$\Pi_m = h \sum_t w_{m,t} r_{m,t} D_t^I q_{m,t} + h \sum_t p_{m,t}^D D_{m,t}^D q_{m,t} - h \sum_t c_g G_m - h \sum_t c_q (1 - q_{m,t}) L_{m,t}. \quad (5)$$

闲置成本 $c_g G_m$ 按固定算力计——无论是否用满都付，这是厂家有动机降低谷价以填谷的根源，也是本文与”容量为常数、无闲置成本”模型的关键区别。中间商利润为零售收入减批发成本减 QoS 退化成本。系统利润为两厂家利润加中间商利润。

3 均衡求解

3.1 低维形状参数化

直接让每个厂家在 $2T$ 维（分时批发价加直连价）连续空间中优化，会使 Nash 求解高维、非凸、不可复现——这是同类多层定价博弈反复出现的收敛障碍。本文将厂家的分时定价**参数化为少数标量形状**：

$$w_{m,t} = \bar{w}_m(1 + \delta_m \hat{\ell}_t), \quad p_{m,t}^D = \bar{p}_m^D(1 + \delta_m^D \hat{\ell}_t), \quad (6)$$

其中 $\hat{\ell}_t$ 是零均值的标准化负载形状（由刚性需求基线归一化得到，外生已知），每个厂家的策略压缩为四个标量 $(\bar{w}_m, \delta_m, \bar{p}_m^D, \delta_m^D)$ 。动态强度 $\delta_m = 0$ 对应统一定价； $\delta_m > 0$ 对应高峰提价。这一约束以“形状族内最优”换取可复现性：本文不声称 $2T$ 维连续空间的全局最优，只声称该形状族内的均衡。

3.2 虚拟博弈与极限环的解决

厂家的最优响应通过对四标量的**粗网格搜索**计算（对非光滑 QoS 目标鲁棒，成本可预测、可并行）；中间商响应同样用网格搜索，每次评估内嵌 QoS 与路由的**联合固定点**（一次阻尼迭代，而非嵌套求解，避免拥塞下的成本爆炸）。

朴素的最优响应迭代（厂家轮流对手当前策略最优响应）在拥塞区间出现**极限环振荡**：策略在两组配置间循环往复，永不收敛。这与寡头定价博弈的已知现象一致。本文改用**虚拟博弈 (fictitious play)**：每个厂家对对手的**运行平均策略**最优响应，历史平均天然阻尼振荡。收敛判据采用 **regret**（厂家相对时间平均策略的单边最大偏离收益）而非参数漂移——后者在求解器分辨率下会误报。

评注 1 (收敛性, 含诚实边界). 非拥塞区间, QoS 恒为 1、固定点单步收敛, 网格求解完全确定性, 跨随机种子系统利润相对标准差为 4.31×10^{-4} , 收敛性完全可靠。拥塞区间则需谨慎：在**粗网格**下虚拟博弈的 **regret** 单调下降 ($133.6 \rightarrow 63.7 \rightarrow \dots \rightarrow 4.98$, 22 轮达到 $regret < 5$)；但在**细网格**下 **regret** 在约第 10 轮触底于 ≈ 14 后不降反升、40 轮后漂移到 ≈ 22 , **未能达到收敛判据**。这说明粗网格的“ $regret = 4.98$ 收敛”部分是粗粒度掩盖了可盈利偏离的假象——更细的偏离候选暴露出该拥塞博弈在本文求解预算内**并非可靠收敛**。因此本文对拥塞区间只作分辨率稳健的定性结论（见第 4 节），不依赖任何依赖完全收敛的定量声明。

4 实验结果

4.1 设置

$T = 8$ 时段、 $h = 3$ 小时。基准算力 $G_A = 1500, G_B = 600$ ；拥塞情形将算力收紧至 $G_A = 300, G_B = 120$ 以激活 QoS 退化。两类用户人口占比基准 $(\pi_R, \pi_E) = (0.6, 0.4)$ ；拥塞情形取 $(0.4, 0.6)$ 以加大高峰压力。所有经济参数为合成标定，具体数值仅支撑机制方向，不作生产预测。完整参数见补充材料。

4.2 非拥塞区间：负载迁移稳健，利润中性

基准算力下市场不拥塞（统一定价峰值利用率仅 0.213），QoS 恒为 1。表 1 给出统一与动态定价对比。

表 1: 非拥塞区间：统一定价 vs 动态定价（确定性网格求解）

指标	统一定价	动态定价
系统利润	1193.3	1139.4
峰值利用率	0.213	0.261
弹性需求时段重心位移		+0.177
刚性需求时段重心位移		+0.077

负载迁移 (P1) 稳健：动态定价下弹性需求的时段重心后移 +0.177，刚性需求仅 +0.077——弹性负载迁移强度约为刚性的 2.3 倍，符合“动态定价主要驱动时间弹性负载迁移”的机制预期。但在不拥塞的市场，QoS 本就为 1、无可保护，动态定价的利润效应中性到微负（弹性占比扫描下增益为 0%, -0.32%, -4.51%, -3.76%, -3.00%）。这说明动态定价的价值前提是**市场确实拥塞**。

4.3 拥塞区间：QoS 保护稳健，利润打平

收紧算力后，统一定价使市场真正拥塞。表 2 给出虚拟博弈求解的结果，并列粗、细两种网格分辨率以检验鲁棒性。

表 2: 拥塞区间：统一 vs 动态定价（虚拟博弈均衡），含网格鲁棒性检验

指标	统一定价	动态（粗网格）	动态（细网格）
峰值利用率	0.782	0.706	0.666
最低 QoS	0.756	0.968	0.990
系统利润	1783	1949	1749
利润变化	—	+9.3%	-1.9%

QoS 保护 (P2、P3) 稳健、分辨率无关。统一定价使最低 QoS 跌至 0.756、峰值利用率达 0.782。动态定价将峰值利用率削至 0.66–0.71、最低 QoS 恢复到 0.97–0.99。削峰与 QoS 保护在粗、细两种网格下方向一致，是稳健结论。

利润效应近似中性、不稳健。系统利润变化在粗网格下为 +9.3%，在细网格下翻转为 -1.9%。利润变化的符号本身随求解精度翻转，且细网格虚拟博弈本身未收敛（regret 漂移至 ≈ 22 ，见第 3 节评注），故真实利润效应接近于零、被求解误差淹没。因此本文只声称动态定价利润**近似中性**，不声称提升利润。

被撤回的假设。我们曾假设小算力厂家更依赖动态定价（动态强度 $\delta_B > \delta_A$ ）。粗网格给出 $\delta_A = 0.383 \gg \delta_B = 0.023$ （大厂主导），细网格给出 $\delta_A = 0.059, \delta_B = 0.278$ （小厂主导）——方向随网格翻转。该假设在任一方向上都不稳健，应予撤回。同样，负载迁移非对称性 (P1) 在非拥塞区稳健，但在拥塞均衡处抹平（细网格弹性/刚性重心 4.23 对 4.31，差异微弱）。

5 讨论：为什么利润打平

拥塞区间的核心现象是 QoS 大幅改善（0.756 $\rightarrow$ 0.97 以上）而利润近似不变。这并非数值巧合，而是有经济机制的结果。

5.1 剩余重分配而非创造

关键前提是**算力固定、需求总量基本固定**。动态定价只在时间维度上重排需求，不创造新算力或新需求。其对厂家利润的影响分解为方向相反的两组力量。正向：高峰提价提高单位毛利；低谷降价利用闲置算力产生额外结算量；削峰使 QoS 回升、有效结算量增加。负向：高峰提价驱离价格敏感需求（流向对手、直连或退出）；低谷降价摊薄单位毛利；被挤出的弹性用户部分净退出。高峰”提价多赚”被”驱离需求少赚”抵消，低谷”填谷多做量”被”低价薄利”抵消，厂家总利润近似不变。这与价格歧视的标准结论一致：供给与需求总量固定时，时间价格歧视主要重新分配剩余，不必然放大厂家利润。

5.2 削峰省下的损失为何没变成利润

QoS 从 0.756 回升到 0.97 以上、少折损大量请求，直觉上应是纯增益。两个原因使其未落到厂家利润：第一，**削峰是靠驱离高峰需求实现的**——把利用率从 0.78 压到 0.66 必须挤走部分高峰用户，QoS 回升多结算的量大致等于被挤走需求的损失，保 QoS 的代价恰是丢需求。第二，**竞争与退出选项封住涨价空间**——异质双厂家竞争加直连/退出选项，使任一厂家无法靠提价独吞 QoS 改善的剩余；该剩余更多流向用户（体验改善、价格被竞争压制），而非厂家利润。

5.3 政策与运营含义

这一发现与”动态定价/surge pricing 是厂家趁拥塞牟利的工具”的通常预期相反。在竞争、算力固定、用户可退出的推理服务市场，分时定价主要是**QoS 保护工具**，厂家并不因此显著多赚。监管含义：监管者不必将分时定价视为牟利手段，其剩余主要流向服务质量与用户体验。运营含义：运营者采用分时定价的正当理由应是保障 SLA 与服务质量，而非提升收入——把它当收入工具会落空。

6 局限

第一，全部经济参数（价格敏感度、迁移成本、容量成本、弹性人口占比、退出效用）为合成标定，无真实请求轨迹校准；具体百分比不作生产预测，仅支撑机制方向。第二，厂家策略限定在低维形状族内，不声称连续策略空间的全局最优；更重要的是，**拥塞区间的虚拟博弈在细网格下并未收敛**——regret 在约第 10 轮触底于 ≈ 14 后漂移至 40 轮的 ≈ 22 ，远未达到 < 5 判据，故拥塞细网格的利润与策略数（含 -1.9% 、 δ 值）均为未收敛快照，仅用于说明”利润方向不稳健”。粗网格的”regret= 4.98 收敛”则部分是粗粒度掩盖可盈利偏离的假象。这意味着拥塞区间的**定量结论**（利润、哪个厂家更动态）尚不可靠，只有**定性的** QoS 保护方向（削峰、最低 QoS 回升）在粗细网格下一致，可作为本文的稳健主张。彻底解决拥塞均衡的可靠求解（更强的平均化、变分不等式重构或更细的收敛预算）是必要的后续工作。第三，本文为两厂家、单中间商结构；更多厂家、多中间商、长期容量合约与模型路由的复杂交互留待后续。第四，QoS 退化用合成 sigmoid 曲线，真实后端的完成率/延迟曲线需用受控测量或生产轨迹替换重标。第五，利润打平的结论建立在”算力与需求总量固定”前提上；若需求总量本身对价格高度弹性、或算力可短期调整，结论可能改变。

7 结论

本文研究算力固定下推理服务的分时动态定价能否保护服务质量。我们建立异质双厂家竞争、中间商路由、两类用户加退出选项的市场模型，用低维形状参数化加虚拟博弈求解厂家 Nash 竞争，解决了朴素最优响应在拥塞区间的极限环振荡，使均衡求解可复现。经粗、细网格的对抗性鲁棒性检验，核心结论是：**分时动态定价在市场拥塞时是可靠的 QoS 保护工具**（削峰、把最低 QoS 从 0.756 恢复到 0.97 以上，分辨率无关），**但对厂家利润近似中性**（利润变化符号随求解精度翻转）。我们从剩余重分配的角度解释这一利润打平：算力与需求固定时，分时定价重排而非放大剩余，QoS 改善的剩余在竞争与退出约束下流向用户。这一发现与“动态定价牟利”预期相反，其监管与运营含义是：分时定价的正当理由是保障服务质量，而非提升收入。未来工作包括真实轨迹校准、拥塞区间的完全收敛与置信区间、以及多厂家多中间商扩展。

代码与工件可用性

削峰填谷仿真模块为 `pricing_sim/peak_shaving_config.py`、`pricing_sim/peak_shaving_market.py`、`pricing_sim/peak_shaving_equilibrium.py`；实验入口为 `experiments/run_peak_shaving_experiments.py`（非拥塞主实验）、`experiments/run_peak_shaving_congested_fp.py`（拥塞虚拟博弈）、`experiments/run_fp_dynamic_converge.py`（regret 收敛与断点续跑）、`experiments/run_peak_shaving_robustness.py`（QoS 形态、退出效用、跨种子）。机器可读工件在 `artifacts/peak_shaving/20260618/`，每个正文数字对应一条落盘 JSON 记录。

参考文献

- [1] Daniel Crankshaw, Xin Wang, Guilio Zhou, Michael J. Franklin, Joseph E. Gonzalez, and Ion Stoica. Clipper: A low-latency online prediction serving system. In *14th USENIX Symposium on Networked Systems Design and Implementation (NSDI 17)*, pages 613–627, 2017. URL <https://www.usenix.org/conference/nsdi17/technical-sessions/presentation/crankshaw>.
- [2] Arpan Gujarati, Reza Karimi, Safya Alzayat, Wei Hao, Antoine Kaufmann, Ymir Vigfusson, and Jonathan Mace. Serving DNNs like clockwork: Performance predictability from the bottom up. In *14th USENIX Symposium on Operating Systems Design and Implementation (OSDI 20)*, 2020. URL <https://www.usenix.org/conference/osdi20/presentation/gujarati>.
- [3] Gyeong-In Yu, Joo Seong Jeong, Geon-Woo Kim, Soojeong Kim, and Byung-Gon Chun. Orca: A distributed serving system for transformer-based generative models. In *16th USENIX Symposium on Operating Systems Design and Implementation (OSDI 22)*, pages 521–538, 2022. URL <https://www.usenix.org/conference/osdi22/presentation/yu>.
- [4] Woosuk Kwon, Zhuohan Li, Siyuan Zhuang, Ying Sheng, Lianmin Zheng, Cody Hao Yu, Joseph E. Gonzalez, Hao Zhang, and Ion Stoica. Efficient memory management for large language model serving with PagedAttention. In *Proceedings of the 29th Symposium on Operating Systems Principles*, pages 611–626, 2023. doi: 10.1145/3600006.3613165. URL <https://doi.org/10.1145/3600006.3613165>.
- [5] Amey Agrawal, Nitin Kedia, Ashish Panwar, Jayashree Mohan, Nipun Kwatra, Bhargav Gulavani, Alexey Tumanov, and Ramachandran Ramjee. Taming Throughput-Latency tradeoff in LLM inference

- with Sarathi-Serve. In *18th USENIX Symposium on Operating Systems Design and Implementation (OSDI 24)*, pages 117–134. USENIX Association, 2024. URL <https://www.usenix.org/conference/osdi24/presentation/agrawal>.
- [6] Fred C. Schweppe, Michael C. Caramanis, Richard D. Tabors, and Roger E. Bohn. *Spot Pricing of Electricity*. Springer, 1988. doi: 10.1007/978-1-4613-1683-1. URL <https://doi.org/10.1007/978-1-4613-1683-1>.
- [7] Severin Borenstein. The long-run efficiency of real-time electricity pricing. *Energy Journal*, 26(3):93–116, 2005. doi: 10.5547/ISSN0195-6574-EJ-Vol26-No3-5. URL <https://doi.org/10.5547/ISSN0195-6574-EJ-Vol26-No3-5>.
- [8] M. H. Albadi and E. F. El-Saadany. A summary of demand response in electricity markets. *Electric Power Systems Research*, 78(11):1989–1996, 2008. doi: 10.1016/j.epsr.2008.04.002. URL <https://doi.org/10.1016/j.epsr.2008.04.002>.
- [9] Ahmad Faruqui and Sanem Sergici. Household response to dynamic pricing of electricity: A survey of 15 experiments. *Journal of Regulatory Economics*, 38:193–225, 2010. doi: 10.1007/s11149-010-9127-y. URL <https://doi.org/10.1007/s11149-010-9127-y>.
- [10] Pierluigi Siano. Demand response and smart grids—a survey. *Renewable and Sustainable Energy Reviews*, 30:461–478, 2014. doi: 10.1016/j.rser.2013.10.022. URL <https://doi.org/10.1016/j.rser.2013.10.022>.