

补充材料：算力固定下的推理服务分时动态定价

匿名作者

2026 年 6 月 19 日

S1. 参数表

表 1 给出正文削峰填谷实验的主要参数。除特别说明外，参数来自代码文件pricing_sim/peak_shaving_config.py。这些参数是合成标定，用于说明机制方向，不代表生产环境预测。

表 1: 主要仿真参数

参数	取值	含义
T	8	一天划分为 8 个时段。
h	3 小时	每个时段长度。
G_A, G_B (基准)	1500, 600	两家厂家的固定算力。
G_A, G_B (拥塞)	300, 120	激活 QoS 退化的拥塞设定。
π_R, π_E (基准)	0.6, 0.4	刚性用户与弹性用户占比。
π_R, π_E (拥塞)	0.4, 0.6	拥塞实验中提高弹性用户占比。
base_rigid	200,150,300,600, 800,900,700,250	刚性需求基线。
time_preference	0.30,0.20,0.50,0.80, 1.00,1.00,0.90,0.40	外生时段偏好。
intermediary_brand	1.05	中间商便利性参数。
firm_brand	(1.0,1.0)	两家厂家服务近似同质。
flexible_baseline	400	弹性需求基准规模。
rigid_wtp	1.80	刚性/重放需求的保留价值。
rigid_churn_rate	5.0	刚性需求价格响应斜率。
market_growth	1.2	低价时的弹性市场扩张强度。
p_0	0.80	基准价格。
直连价格区间	[0.45, 2.10]	厂家直连零售价约束。
批发价格区间	[0.25, 0.90]	厂家批发价约束。
α_R, α_E	2.0, 5.0	刚性/弹性用户价格敏感度。
c_s^R, c_s^E	0.60, 0.10	刚性/弹性用户迁移成本。
$\bar{u}$	0.82	QoS 退化阈值。
qos_strength	15.0	阈值型 QoS 退化强度。

参数	取值	含义
γ	1.0	QoS 反馈权重。
c_g	0.015	固定算力持有成本。
c_q	0.35	QoS 退化成本。
u_0	0.0	no-purchase 退出选项效用。

S2. 策略形状与网格

厂家策略限制在四个标量：

$$(\bar{w}_m, \delta_m, \bar{p}_m^D, \delta_m^D).$$

正文中的分时价格由

$$w_{m,t} = \bar{w}_m(1 + \delta_m \hat{\ell}_t), \quad p_{m,t}^D = \bar{p}_m^D(1 + \delta_m^D \hat{\ell}_t)$$

生成，并裁剪到价格上下界内。统一定价实验通过将 $\hat{\ell}_t$ 置零实现，因此即使求解器内部保留 δ 参数，最终价格仍然不随时段变化。

粗网格虚拟博弈使用

$$\begin{aligned} \bar{w} &\in \{0.30, 0.85\}, & \delta &\in \{-0.4, -0.133, 0.133, 0.4\}, \\ \bar{p}^D &\in \{0.70, 1.50\}, & \delta^D &\in \{-0.4, -0.133, 0.133, 0.4\}. \end{aligned}$$

细网格复核使用

$$\begin{aligned} \bar{w} &\in \{0.27, 0.575, 0.88\}, & \delta &\in \{-0.4, -0.2, 0, 0.2, 0.4\}, \\ \bar{p}^D &\in \{0.60, 1.10, 1.60\}, & \delta^D &\in \{-0.4, -0.2, 0, 0.2, 0.4\}. \end{aligned}$$

中间商响应使用三标量网格：零售基准价、零售动态强度和路由价格敏感度。

S3. 正文数字与工件映射

表 2: 正文关键数字的工件来源

正文位置	工件	字段
非拥塞统一/动态利润与利用率	peak_shaving_summary.json	uniform, dynamic。
非拥塞负载迁移	peak_shaving_summary.json	P1_migration.rigid_shift, P1_migration.elastic_shift。
弹性占比扫描	peak_shaving_summary.json	elastic_sweep。

正文位置	工件	字段
拥塞统一定价基准	peak_shaving_ congested_fp.json	uniform.system_profit, uniform.peak_util, uniform. min_qos_firm。
拥塞动态粗网格	peak_shaving_fp_ dynamic_converged. json	system_profit, peak_util, min_ qos, delta_A, delta_B。
拥塞动态细网格	peak_shaving_fp_ dynamic_converged_ fine.json	system_profit, peak_util, min_ qos, delta_A, delta_B。
细网格 regret	fp_dynamic_ckpt_ fine.json	round=40, maxreg=22.3029。
粗网格 regret	fp_dynamic_ckpt.json	round=22, maxreg=4.9821。
机制诊断与图表	artifacts/peak_ shaving/20260619/	peak_shaving_diagnostics.json, peak_shaving_mechanism_ summary.csv, peak_shaving_ time_profiles.csv。
混合策略诊断	artifacts/peak_ shaving/20260619_ submission/peak_ shaving_mixed_ oracle.json	trace, expected_metrics, row_ mix, col_mix。
参数压力测试	artifacts/peak_ shaving/20260619_ submission/peak_ shaving_parameter_ sweep_summary.json	9 个扰动场景的 QoS 增益、峰值利用 率下降和利润符号。
公开价格锚点	public_api_price_ anchor.json	Z.AI、DeepSeek 和 OpenAI 公开 API 价格，访问日期为 2026-06-19。
vLLM QoS 测量锚点	vllm_qos_anchor_ summary.json, vllm_qos_anchor_ points.csv	两个单 GPU 受控过载剖面的 TTFT-SLA 曲线、拟合参数和图表 来源。

S4. 机制诊断和图表来源

正文新增的机制诊断图表由 `experiments/build_peak_shaving_diagnostics.py` 生成。该脚本不重新搜索均衡，只读取已有策略工件并重建三个对象：拥塞统一定价基准、动态粗网格时间平均策略、动态细网格快照。输出包括：

- `artifacts/peak_shaving/20260619/peak_shaving_diagnostics.json`: 完整诊断数据, 包括价格、路由、需求、QoS、退出概率、inclusive value 和利润组成。
- `artifacts/peak_shaving/20260619/peak_shaving_mechanism_summary.csv`: 正文机制段使用的摘要指标。
- `artifacts/peak_shaving/20260619/peak_shaving_time_profiles.csv`: 时段需求、服务量、利用率和 QoS 剖面。
- `figures/peak_shaving_diagnostics/`: 正文图 1–4 使用的 PDF 图表。

诊断脚本内置一致性检查: 重建得到的统一、动态粗网格和动态细网格系统利润需与 20260618 工件中的已报告数值一致。当前运行没有触发 validation warning。

S5. 投稿增强实验与校准锚点

细网格单快照在 40 轮后仍有较高 regret。为避免把单个快照误读为均衡, 本文增加 `experiments/run_peak_shaving_mixed_oracle.py`。该脚本使用完整 225 点细网格, 以双重 oracle 方式反复加入当前混合剖面的最优偏离, 并在受限支持上运行经验虚拟博弈。当前运行在第 5 轮得到 5×5 支持, 完整细网格最大 regret 为 0.2025。对应混合剖面的期望峰值利用率为 0.7030, 最低 QoS 为 0.9699, 系统利润为 1733.13。

参数压力测试由 `experiments/run_peak_shaving_parameter_sweep.py` 生成。它评估容量规模、价格敏感度、迁移成本和 QoS 阈值的 9 个局部扰动场景。动态粗网格和动态细网格快照在所有 9 个场景中均保持正的最低 QoS 增益和正的峰值利用率下降; 但利润仍不稳健, 动态细网格只有 1 个场景为正。

公开 API 价格锚点存放于 `artifacts/peak_shaving/20260619_submission/public_api_price_anchor.json`。Z.AI 官方价格页给出 GLM-4.7 每百万 token 输入 \$0.6、输出 \$2.2; DeepSeek 官方价格页给出 deepseek-chat cache-miss 输入 \$0.27、输出 \$1.10; OpenAI 官方 GPT-4o 页面给出输入 \$2.50、输出 \$10.00。该锚点只用于说明本文归一化价格处在真实 API 价格数量级内, 不用于估计需求弹性或 QoS 曲线。

受控 vLLM QoS 测量锚点由 `experiments/build_peak_shaving_measurement_anchor.py` 生成。输入为两组已有重复测量工件: `artifacts/vllm-study/20260531-190126/controlled_aggregate.csv` 和 `artifacts/vllm-study-qwen25-3b/20260531-214710/controlled_aggregate.csv`。两组测量均使用 vLLM 0.22.0 和 NVIDIA GeForce RTX 4090, QoS 观测量为 0.5 秒首 token 延迟 SLA 达标率。表 3 给出拟合到 $q(u) = \exp[-\kappa(u - \bar{u})^2]$ 后的参数。该锚点用于约束 QoS 退化形态, 不用于估计需求弹性、迁移成本或生产到达过程。

表 3: 受控 vLLM 单 GPU QoS 测量锚点

剖面	最大健康并发	$\bar{u}$	κ	RMSE	首次 SLA 下降并发	最低观测 QoS
Qwen2.5-0.5B	224	1.000	0.517	0.068	384	0.500
Qwen2.5-3B	224	1.058	0.942	6.3×10^{-10}	384	0.667

S6. 复现命令

以下命令应在 WSL 项目目录 `/root/paper_code/0427_tokenrl/paper_token_cross_survey` 中运行。当前仓库使用 `requirements.txt`，未迁移为 `pyproject.toml`。

```
python -m pip install -r requirements.txt
python experiments/run_peak_shaving_experiments.py
python experiments/run_peak_shaving_congested_fp.py
python experiments/run_fp_dynamic_converge.py
FP_TAG=fine python experiments/run_fp_dynamic_converge.py
python experiments/run_peak_shaving_robustness.py
uv run --with-requirements requirements.txt \
    python experiments/build_peak_shaving_diagnostics.py
uv run --with-requirements requirements.txt \
    python experiments/run_peak_shaving_parameter_sweep.py
uv run --with-requirements requirements.txt \
    python experiments/run_peak_shaving_mixed_oracle.py
uv run --with-requirements requirements.txt \
    python experiments/build_peak_shaving_measurement_anchor.py
```

编译正文与补充材料：

```
xelatex -interaction=nonstopmode -halt-on-error \
    peak_shaving_dynamic_pricing_2026-06-19.tex
bibtex peak_shaving_dynamic_pricing_2026-06-19
xelatex -interaction=nonstopmode -halt-on-error \
    peak_shaving_dynamic_pricing_2026-06-19.tex
xelatex -interaction=nonstopmode -halt-on-error \
    peak_shaving_dynamic_pricing_2026-06-19.tex
xelatex -interaction=nonstopmode -halt-on-error \
    peak_shaving_dynamic_pricing_supplement_2026-06-19.tex
```

S7. 已知限制

拥塞区间的细网格单快照在 40 轮内没有达到 $\text{regret} < 5$ 的判据。因此，细网格快照利润、动态强度和时段重心等数值仍只能作为未收敛快照使用。混合策略诊断显著降低了有限细网格上的 regret，但它仍是 225 点候选集上的混合/平均策略诊断，不是连续策略空间的全局均衡证明。

本文没有使用真实请求轨迹校准价格敏感度、迁移成本和退出效用。公开 API 价格只提供价格尺度锚点，受控 vLLM 测量只提供单 GPU、小模型、短生成长度下的 QoS 形态锚点。二者都不能替代真实负载、长上下文、多模型、多 GPU 和用户行为校准。后续工作需要用生产轨迹重新标定这些参数，并报告跨参数、跨网格和跨求解预算的置信区间或 exploitability 边界。