

补充材料：面向 Token 推理服务的三方跨时段定价博弈

本补充材料保存主文压缩过程中移出的参数、诊断、鲁棒性、用户保护、厂家直供 API 和校准压力实验。补充材料中的数值均来自 2026-06-08 重跑工件。这些结果用于支撑边界检查和可复核性，不把数值候选提升为全局 Nash 证书或生产部署结论。

S1 完整仿真参数与来源审计

表 1: 仿真参数设置

参数	符号	值	含义
市场结构参数			
时段数	T	8	每日调度窗口
中间商数	J	3	竞争渠道数目
每时段时长	h	3.0	小时
需求基数组件	–	刚性 200–900/弹性 400	按时段变化
容量参数			
各中间商容量预算	G_j	(1050, 1080, 1080)	归一化日容量单位
容量正下界	$\underline{g}$	10^{-6}	避免利用率奇异的数值下界
单位容量成本	c_g	0.015	每单位容量每小时成本
价格参数			
基准批发价	w_0	0.40	初始统一批发价
基准零售价	p_0	0.80	固定基线零售价
批发价边界	$[\underline{w}, \overline{w}]$	[0.25, 0.90]	平台候选范围
零售价边界	$[\underline{p}, \overline{p}]$	[0.45, 2.10]	中间商可行范围
刚性支付意愿	$\bar{v}$	1.80	刚性需求保留价格
刚性流失速率	β	5.0	sigmoid 需求响应陡度
弹性市场增长	$\bar{g}$	1.2	低价吸引额外需求的增长因子
QoS 参数			
退化阈值利用率	$\bar{u}$	0.82	QoS 开始下降的利用率临界值
退化强度	κ	15.0	$\exp[-\kappa(u - \bar{u})^2]$ 中的衰减速率
单位退化成本	c_q	0.35	每单位需求 QoS 退化的惩罚成本
QoS 反馈权重	γ	1.0	logit 效用中 $(1 - q)$ 的系数
用户行为参数			
价格敏感度	α	3.5	确定性效用中价格的系数
时段偏好	a_t	(0.30, 0.20, 0.50, 0.80, 1.00, 1.00, 0.90, 0.40)	各时段相对偏好
迁移成本	c_s	0.20	跨时段迁移的效用惩罚
品牌质量	b_j	(1.04, 1.00, 0.96)	中间商品品牌吸引力因子
算法参数			
多起点搜索批数	K	8	平台层随机重启次数
SLSQP 最大迭代	M	140	每个中间商最优响应的迭代上限
最优响应轮数	B	24	中间商层 Gauss–Seidel 轮数上限
固定点阻尼系数	η	0.35	用户层 QoS 迭代更新阻尼权重
固定点收敛容差	ϵ	10^{-9}	QoS 残差阈值
固定点最大迭代	L	200	用户层固定点最大迭代次数
有限博弈人数	N	60	有限参与者拥塞博弈用户数

表 2: 关键参数来源审计

参数	符号	基准值/来源值	来源类型	仍需校准的含义
基准 QoS 阈值	$\bar{u}$	0.82	合成	基准 QoS 退化阈值
基准 QoS 强度	κ	15.0	合成	基准 QoS 退化强度
vLLM QoS 剖面	$\bar{u}, \kappa$	1.00/0.52; 1.06/0.94	测量拟合	受控 vLLM QoS 曲线
到达率形态	a_t	8/16/32 rps 重放	测量重放	受控到达率峰谷形态
价格敏感度	α	3.5	合成	用户需求弹性
迁移成本	c_s	0.20	合成	跨时段迁移摩擦
单位容量成本	c_g	0.015	合成	中间商运营成本
单位退化成本	c_q	0.35	合成	SLA 违约或流失惩罚
QoS 反馈权重	γ	1.0	合成	用户对 QoS 下降的响应
直供 API 偏好	b_0	1.08	假设	直供品牌/便利性偏好

刚性需求采用

$$D_{j,t}^{\text{rigid}} = a_t^{\text{base}} \sigma[\beta(\bar{v} - p_{j,t})] \sum_k s_{k,t},$$

弹性需求采用 logit 份额分配:

$$s_{j,t} = \frac{\exp(V_{j,t})}{\sum_{k,\tau} \exp(V_{k,\tau})}, \quad V_{j,t} = \ln b_j + \ln a_t - \alpha[p_{j,t} + c_s(1 - \pi_t) - p_0] - \gamma(1 - q_{j,t}).$$

其中 π_t 表示用户原生时段分布, 在没有真实原生调用时段数据时由 a_t 归一化得到。

S2 主结果可视化与机制诊断




图 1: 三方市场不同策略的系统利润、最低 QoS 和峰值利用率比较。




图 2: 完整候选解附近的中间商利润切面诊断。左图扫描峰值时段零售价, 右图扫描低偏好时段向峰值时段的容量转移。

表 3: 有限用户 PSNE 经验分布与连续 logit SUE 份额的差距

有限用户数	重复次数	平均 L_1 份额差距	平均最大单元差距	平均余弦相似度
60	4	0.3156	0.0510	0.9657
120	4	0.2240	0.0363	0.9801
240	4	0.1558	0.0162	0.9906

S3 鲁棒性、采样收敛与测量 QoS

本节包含两类数值设置。平台候选数量收敛、容量消融、测量 QoS 替换和平台参考候选搜索用于补充主实验机制；需求规模压力测试和 QoS 阈值敏感性采用筛查型配置以控制扫描成本，其脚本入口为 `experiments/run_intermediary_sci_experiments.py`，其中 `SCREENING_TRIALS=3` 且 `SCREENING_MAXITER=60`。因此，表 6 中 $\rho = 1.00$ 的三层 QoS 感知结果用于横向比较需求规模变化下的趋势，不替代表 4 和主文完整候选搜索下的主数值结论。




图 3: 平台批发价候选数量对系统利润、最低 QoS 和峰值利用率的影响。

表 4: 平台候选数量收敛实验

候选数 K	平台收入	系统利润	最低 QoS	最大 regret
1	2691.97	9444.10	1.0000	0.00
2	3510.53	9529.36	1.0000	2.31×10^{-7}
4	4013.46	9525.12	1.0000	1.66×10^{-7}
8	4013.46	9525.12	1.0000	1.66×10^{-7}




图 4: 容量固定与策略性容量分配的消融对比。

表 5: 容量固定消融实验

容量模式	系统利润	最低 QoS	峰值利用率	最大 regret
固定容量	8949.98	0.9977	0.8324	3.61×10^{-8}
策略性容量	9525.12	1.0000	0.8200	1.66×10^{-7}




图 5: 需求规模变化下统一零售和三层 QoS 感知策略的利润与 QoS 对比。

表 6: 需求规模压力测试（筛查设置）

需求比例 ρ 与策略	系统利润	最低 QoS	峰值利用率	最大 regret
0.85 统一零售	4464.62	0.9819	0.8549	—
0.85 三层 QoS 感知	7380.68	1.0000	0.8200	4.96×10^{-10}
1.00 统一零售	4911.97	0.8428	0.9268	—
1.00 三层 QoS 感知	8708.64	1.0000	0.8198	9.77×10^{-10}
1.15 统一零售	4690.49	0.6702	0.9833	—
1.15 三层 QoS 感知	10036.60	1.0000	0.8194	1.57×10^{-9}
1.30 统一零售	3803.70	0.4800	1.0412	—
1.30 三层 QoS 感知（压力）	11357.67	0.9999	0.8222	0.0186




图 6: QoS 退化阈值变化下三层 QoS 感知策略的利润、QoS 和利用率。

表 7: vLLM 后端测量 QoS 曲线下的三层候选结果

QoS 剖面	$\bar{u}$	κ	RMSE	系统利润	活跃最低 QoS	需求加权 QoS	最大 regret
合成默认	0.8200	15.00	—	9525.12	1.0000	1.0000	1.66×10^{-7}
vLLM 剖面 A	1.0000	0.52	0.0683	9525.15	1.0000	1.0000	3.64×10^{-9}
vLLM 剖面 B	1.0582	0.94	6.33×10^{-10}	9525.08	1.0000	1.0000	2.82×10^{-10}

表 8: 平台候选参考搜索与收入 gap

候选数 K	平台收入	平台收入 gap	系统利润	系统利润损失	最大 regret
4	4013.46	0.00	9525.12	0.00	1.66×10^{-7}
8	4013.46	0.00	9525.12	0.00	1.66×10^{-7}
16	4013.46	0.00	9525.12	0.00	1.66×10^{-7}

S4 用户保护与厂家直供 API 敏感性




图 7: 用户保护价格上限扫描下的平台收入–inclusive value 权衡。

表 9: 用户保护价格上限敏感性代表点

零售价上限	批发价上限	平台收入	系统利润	Inclusive value	活跃最低 QoS	解释
0.80	0.80	4184.13	5294.55	2.1359	1.0000	保护策略
0.80	0.90	4635.85	5294.55	2.1359	1.0000	高平台收入，低中间商利润
0.82	0.80	4181.71	5427.30	2.0659	1.0000	用户效用低于统一零售
0.85	0.90	4628.62	5625.46	1.9609	1.0000	价格上限过宽




图 8: 厂家直供 API 价格–容量敏感性。

表 10: 厂家直供 API 价格-容量敏感性代表点

直供价	直供容量	平台收益	系统利润	Inclusive value	活跃最低 QoS	直供份额	解释
0.75	500	3573.78	4607.35	2.3399	1.32×10^{-7}	24.08%	容量不足
0.75	1500	5579.00	6627.77	2.4927	1.0000	25.73%	最高用户体验
0.82	1500	5705.80	6762.33	2.4253	1.0000	25.01%	原直供设置
1.00	1500	6030.58	7108.48	2.3003	1.0000	23.45%	最高平台收益

S5 校准扰动、vLLM 压力与到达率重放




图 9: 合成经济参数扰动下的校准不确定性扫描。

表 11: 校准不确定性扫描代表点

扰动场景	策略	平台收入增益	Inclusive value 增益	活跃最低 QoS	解释
低价格敏感度	用户保护	1525.73	0.0282	1.0000	三项改善
低价格敏感度	直供 API	3053.58	0.3252	1.0000	三项改善
高价格敏感度	直供 API	3129.77	0.3196	1.0000	三项改善
高迁移成本	用户保护	1651.31	0.0479	1.0000	三项改善
低 QoS 反馈	用户保护	1616.89	0.0185	1.0000	三项改善
高需求规模	用户保护	2323.38	0.1422	0.9296	收入-体验仍改善
高需求规模	直供 API	4285.77	0.4238	6.80×10^{-10}	直供通道拥塞
低直供偏好	直供 API	3087.64	0.3057	1.0000	三项改善

表 12: vLLM 后端测量 QoS 下的需求压力测试

QoS 剖面	需求比例 ρ	系统利润	活跃最低 QoS	需求加权 QoS	峰值利用率	最大 regret
vLLM-0.5B	1.00	9525.15	1.0000	1.0000	1.0000	3.64×10^{-9}
vLLM-0.5B	1.15	10975.58	1.0000	1.0000	1.0000	1.46×10^{-8}
vLLM-0.5B	1.30	12426.00	1.0000	1.0000	1.0001	1.28×10^{-8}
vLLM-3B	1.00	9525.08	1.0000	1.0000	1.0582	2.82×10^{-10}
vLLM-3B	1.15	10975.55	1.0000	1.0000	1.0582	2.68×10^{-11}
vLLM-3B	1.30	12425.95	1.0000	1.0000	1.0582	3.04×10^{-10}




图 10: measured-QoS 固定容量压力基线。

表 13: measured-QoS 固定容量压力基线代表点

QoS 剖面	需求比例	容量比例	策略	系统利润	活跃最低 QoS	最大 regret
vLLM-0.5B	1.15	0.85	固定容量	10237.83	0.9752	1.22×10^{-8}
vLLM-0.5B	1.15	0.85	自适应容量	10058.27	1.0000	1.21×10^{-7}
vLLM-0.5B	1.30	0.85	固定容量	11204.87	0.9680	8.71×10^{-9}
vLLM-0.5B	1.30	0.85	自适应容量	11386.18	1.0000	4.35×10^{-8}
vLLM-3B	1.30	1.00	固定容量	11692.49	0.9856	6.67×10^{-9}
vLLM-3B	1.30	1.00	自适应容量	11364.56	1.0000	1.56×10^{-8}

表 14: 测量驱动到达率重放实验

策略	系统利润	平均零售价	Inclusive value	需求加权 QoS	活跃最低 QoS	最大 regret
统一零售	4585.34	0.8000	1.5358	0.8550	0.5980	–
无 QoS 动态定价	8319.08	1.5260	−1.1028	0.8603	0.7275	3.89×10^{-10}
三层 QoS 感知定价	10165.54	1.5217	−0.9754	1.0000	1.0000	4.37×10^{-10}